

Seminario di Calcolo Scientifico Il Metodo delle Iterazioni dei Sottospazi

Ivan Bioli

Università di Pisa

22 Marzo 2021

Setting e assunzioni

Analizzeremo varie varianti del *Metodo delle Iterazioni dei Sottospazi* nelle seguenti ipotesi:

- $A \in \mathbb{C}^{n \times n}$ matrice simmetrica reale o hermitiana
- autovalori $\lambda_1, \lambda_2, \dots, \lambda_n$ ordinati in ordine decrescente di modulo
- relativi autovettori u_1, \ldots, u_n ortonormali
- p un intero 1 , vogliamo calcolare i <math>p autovalori dominanti nell'ipotesi che questi siano separati dal resto dello spettro:

$$|\lambda_1| \ge \cdots \ge |\lambda_p| > |\lambda_{p+1}| \ge \cdots \ge |\lambda_n|$$

Metodo delle Iterazioni Ortogonali

Algorithm Iterazioni ortogonali

- 1: Sia $X \in \mathbb{C}^{n \times p}$ matrice con colonne ortonormali, $X^*X = I_p$
- 2: $X^{(0)} := X, k = 0$
- 3: repeat
- 4: k := k + 1
- 5: $Z^{(k)} := AX^{(k-1)}$
- 6: $Z^{(k)} =: Q^{(k)}R^{(k)}$ /*Fattorizzazione QR di $Z^{(k)*}$ /
- 7: $X^{(k)} = Q^{(k)}$
- 8: $\lambda^{(k)} := diag(R^{(k)})$
- 9: until $\|\lambda^{(k)} \lambda^{(k-1)}\|/\|\lambda^{(k)}\| < tol \text{ or } k > itmax$

Analisi teorica della velocità di convergenza

Teorema (Convergenza dei sottospazi)

Sia $U_p:=[u_1,\ldots,u_p]$ e sia $X^{(0)}\in\mathbb{C}^{n\times p}$ tale che $W_p:=U_p^*X^{(0)}$ sia non singolare. Se $|\lambda_p|>|\lambda_{p+1}|$ vale:

$$an heta^{(k)} \leq \left| rac{\lambda_{p+1}}{\lambda_p}
ight|^k an heta^{(0)}, \qquad heta^{(k)} = \angle (\mathcal{R}(X^{(k)}), \mathcal{R}(U_p))$$

Corollario

Supponiamo che $|\lambda_{j-1}| > |\lambda_j| > |\lambda_{j+1}|$ e che W_j sia non singolare. Allora:

$$\sin \angle (x_j^{(k)}, u_j) \le c \cdot \max \left\{ \left| \frac{\lambda_j}{\lambda_{j-1}} \right|^k, \left| \frac{\lambda_{j+1}}{\lambda_j} \right|^k \right\}$$



Analisi teorica della velocità di convergenza

Teorema (Convergenza degli autovalori)

Supponiamo che

$$|\lambda_1| > \cdots > |\lambda_p| > |\lambda_{p+1}|$$

Allora per gli elementi diagonali della matrice $R^{(k)}$ vale la stima:

$$|r_{ii}^{(k)} - \lambda_i| = O\left(\left|\frac{\lambda_{i+1}}{\lambda_i}\right|^k + \left|\frac{\lambda_i}{\lambda_{i-1}}\right|^k\right)$$

Dobbiamo cercare di accelerare l'algoritmo perché:

- la velocità di convergenza dipende dai rapporti $|\lambda_{i+1}/\lambda_i| \Longrightarrow$ molto lenta potenzialmente
- la convergenza delle autocoppie non è assicurata

Dobbiamo cercare di accelerare l'algoritmo perché:

- la velocità di convergenza dipende dai rapporti $|\lambda_{i+1}/\lambda_i| \Longrightarrow$ molto lenta potenzialmente
- la convergenza delle autocoppie non è assicurata

Dobbiamo cercare di accelerare l'algoritmo perché:

- la velocità di convergenza dipende dai rapporti $|\lambda_{i+1}/\lambda_i| \Longrightarrow$ molto lenta potenzialmente
- la convergenza delle autocoppie non è assicurata

Dobbiamo cercare di accelerare l'algoritmo perché:

- la velocità di convergenza dipende dai rapporti $|\lambda_{i+1}/\lambda_i| \Longrightarrow$ molto lenta potenzialmente
- la convergenza delle autocoppie non è assicurata

Supporremo d'ora in poi che A sia una matrice simmetrica reale o hermitiana definita positiva

Dobbiamo cercare di accelerare l'algoritmo perché:

- la velocità di convergenza dipende dai rapporti $|\lambda_{i+1}/\lambda_i| \Longrightarrow$ molto lenta potenzialmente
- la convergenza delle autocoppie non è assicurata

Supporremo d'ora in poi che A sia una matrice simmetrica reale o hermitiana definita positiva

Teorema

Sia $X^{(0)}$ come nel Teorema 1 e siano $u_i, 1 \leq i \leq p$ gli autovettori corrispondenti ai p autovalori dominanti $\lambda_1, \ldots, \lambda_p$ di A. Allora:

$$\min_{x \in \mathcal{R}(X^{(k)})} \sin \angle (u_i, x) \le c \left(\frac{\lambda_{p+1}}{\lambda_i}\right)^k$$

Dimostrazione

Per induzione

$$A^{k}X^{(0)} = X^{(k)}R, \qquad R = R^{(k)}R^{(k-1)}\cdots R^{(1)}$$

Sia $U \in \mathbb{C}^{n \times n}$ matrice unitaria, tale che $U^*AU = diag(\lambda_1, \dots, \lambda_n) =: \Lambda$.

$$\Lambda = \text{diag}(\Lambda_1, \Lambda_2), \quad \text{$U^*X^{(k)} =: \hat{X}^{(k)} = \left[\begin{array}{c} \hat{X}_1^{(k)} \\ \hat{X}_2^{(k)} \end{array}\right]} \qquad \Lambda_1, \hat{X}_1^{(k)} \in \mathbb{C}^{\rho \times \rho}$$

$$X^{(k)}R = A^k X^{(0)} = U \Lambda^k U^* X^{(0)} = U \begin{bmatrix} \Lambda_1^k \hat{X}_1^{(0)} \\ \Lambda_2^k \hat{X}_2^{(0)} \end{bmatrix} = U \begin{bmatrix} I_p \\ S^{(k)} \end{bmatrix} \Lambda_1^k \hat{X}_1^{(0)}$$

dove
$$S^{(k)} = \Lambda_2^k \hat{X}_2^{(0)} \hat{X}_1^{(0)^{-1}} \Lambda_1^{-k} \in \mathbb{C}^{(n-p) imes p}$$
 e vale

$$s_{ij}^{(k)} = s_{ij} \left(\frac{\lambda_{p+i}}{\lambda_j} \right)^k, \quad s_{ij} := s_{ij}^{(0)} \qquad 1 \leq i \leq n-p, \quad 1 \leq j \leq p$$

Dunque
$$\mathcal{R}(X^{(k)}) = \mathcal{R}\left(U \left[egin{array}{c} I_p \\ S^{(k)} \end{array}
ight]
ight)$$

Dimostrazione

$$\min_{x \in \mathcal{R}(X^{(k)})} \sin \angle (u_i, x) \leq \sin \angle \left(u_i, U\left(\begin{array}{c}I_p\\S^{(k)}\end{array}\right) e_i\right) =$$

$$= \left\| (I - u_i u_i^*) U\left[\begin{array}{c}0\\\vdots\\0\\1\\0\\\vdots\\s_{n-p,i}(\lambda_p + 1/\lambda_i)^k\\\vdots\\s_{n-p,i}(\lambda_n/\lambda_i)^k\right] \right\| / \left\| \left(\begin{array}{c}I_p\\S^{(k)}\end{array}\right) e_i \right\| \leq$$

$$\leq \left\| (I-u_iu_i^*) \left(u_i + \sum_{j=\rho+1}^n s_{j-\rho,i} \left(\frac{\lambda_j}{\lambda_i} \right)^k u_j \right) \right\| = \sqrt{\sum_{j=1}^{n-\rho} s_{ji}^2 \frac{\lambda_{\rho+j}^{2k}}{\lambda_i^{2k}}} \leq \left(\frac{\lambda_{\rho+1}}{\lambda_i} \right)^k \sqrt{\sum_{j=1}^{n-\rho} s_{ji}^2}$$



Accelerazione di Rayleigh-Ritz

IDEA: Fare un cambio di base. Consideriamo la restrizione di A al sottospazio $\mathcal{R}(Q^{(k)})$

$$H^{(k)} := Q^{(k)^*}AQ^{(k)} \in \mathbb{C}^{p \times p}$$
 (quoziente di Rayleigh generalizzato)

Accelerazione di Rayleigh-Ritz

Algorithm Iterazioni ortogonali con accelerazione di Rayleigh-Ritz, versione 1

```
1: Sia X \in \mathbb{C}^{n \times p} matrice con colonne ortonormali, X^*X = I_p
 2: X^{(0)} := X, k = 0
 3: repeat
 4: k := k + 1
 5. Z^{(k)} := AX^{(k-1)}
 6: Z^{(k)} =: Q^{(k)}R^{(k)} /*Fattorizzazione QR di Z^{(k)*}
 7: H^{(k)} := Q^{(k)^*} A Q^{(k)}
    H^{(k)} = F^{(k)} D^{(k)} F^{(k)*}
                                    /*Decomposizione spettrale di H^{(k)*}/
 8:
 9: X^{(k)} = Q^{(k)}F^{(k)}
10: \lambda^{(k)} := diag(D^{(k)})
11: until \|\lambda^{(k)} - \lambda^{(k-1)}\|/\|\lambda^{(k)}\| < tol \text{ or } k > itmax
```

Limiti della prima versione

PROBLEMA: Il costo del quoziente di Rayleigh generalizzato è troppo alto

Iterazione Algoritmo 1	
$Z^{(k)} := AX^{(k-1)}$	p chiamate di <i>OP</i>
$Z^{(k)} =: Q^{(k)} R^{(k)}$	p(p+1)n operaz.
$X^{(k)} = Q^{(k)}$	0 operaz.

Iterazione Algoritmo 2	
$Z^{(k)} := AX^{(k-1)}$	p chiamate di <i>OP</i> , $Z^{(k)}$ sovrascrive $X^{(k)}$
$Z^{(k)} =: Q^{(k)} R^{(k)}$	$p(p+1)n$ operaz., $Q^{(k)}$ sovrascrive $Z^{(k)}$
$H^{(k)} := Q^{(k)*}(AQ^{(k)})$ $H^{(k)} =: F^{(k)}D^{(k)}F^{(k)*}$	p chiamate di OP , $\frac{1}{2}p(p+1)n$ operaz.
$H^{(k)} =: F^{(k)} D^{(k)} F^{(k)^*}$	kp^3 operaz. (k dipende dal metodo)
$X^{(k)} = Q^{(k)}F^{(k)}$	kp^2n operaz. $X^{(k)}$ sovrascrive $Q^{(k)}$

OP: costo della moltiplicazione di un vettore per A

Seconda versione

Cerchiamo di calcolare implicitamente il quoziente di Rayleigh generalizzato, scrivendo $X^{(k)}$ nella forma:

$$X^{(k)} = Z^{(k)}G^{(k)}, \qquad G^{(k)} \in \mathbb{C}^{p \times p} \text{ non singolare}$$

richiedendo:

$$G^{(k)^*}Z^{(k)^*}Z^{(k)}G^{(k)} = I_p, \qquad \left(Z^{(k)}G^{(k)}\right)^*A^{-2}(Z^{(k)}G^{(k)}) = \Delta^{(k)^{-2}}$$

Sostituendo si ottiene:

$$\left(AX^{(k-1)}G^{(k)}\right)^*A^{-2}(AX^{(k-1)}G^{(k)})=G^{(k)^*}G^{(k)}=\Delta^{(k)^{-2}}$$

Dunque la matrice $Y^{(k)} := G^{(k)} \Delta^{(k)}$ è ortogonale e:

$$Y^{(k)^*}Z^{(k)^*}Z^{(k)}Y^{(k)} = \Delta^{(k)^2}$$

Possiamo quindi ricavare $X^{(k)}$ come:

$$X^{(k)} = Z^{(k)}G^{(k)} = Z^{(k)}Y^{(k)}\Delta^{(k)^{-1}}$$

Seconda versione

Algorithm Iterazioni ortogonali con accelerazione di Rayleigh-Ritz, versione 2

```
1: Sia X \in \mathbb{C}^{n \times p} matrice con colonne ortonormali, X^*X = I_p

2: X^{(0)} := X, k = 0

3: repeat

4: k := k + 1

5: Z^{(k)} := AX^{(k-1)}

6: \hat{H}^{(k)} := Z^{(k)*}Z^{(k)}

7: \hat{H}^{(k)} =: Y^{(k)}\Delta^{(k)^2}Y^{(k)*} /*Decomposizione spettrale di \hat{H}^{(k)*}/

8: X^{(k)} = Z^{(k)}Y^{(k)}\Delta^{(k)^{-1}} /*= Z^{(k)}G^{(k)*}/

9: \lambda^{(k)} := diag(\Delta^{(k)})
```

10: **until** $\|\lambda^{(k)} - \lambda^{(k-1)}\|/\|\lambda^{(k)}\| < tol \$ **or** k > itmax

Algoritmo ritzritz

Algorithm Iterazioni ortogonali con accelerazione di Rayleigh-Ritz, versione 3 (ritzritz)

```
1: Sia X \in \mathbb{C}^{n \times p} matrice con colonne ortonormali, X^*X = I_p
 2: X^{(0)} := X, k = 0
 3: repeat
 4: k := k + 1
 5. Z^{(k)} := AX^{(k-1)}
 6: Z^{(k)} =: Q^{(k)}R^{(k)} /*Fattorizzazione QR di Z^{(k)*}
 7: H^{(k)} := R^{(k)} R^{(k)^*}
     H^{(k)} = P^{(k)} \wedge (k)^2 P^{(k)*}
                                            /*Decomposizione spettrale di H^{(k)*}/
 8:
     X^{(k)} = Q^{(k)}P^{(k)}
 9:
     \lambda^{(k)} := diag(\Delta^{(k)})
10:
11: until \|\lambda^{(k)} - \lambda^{(k-1)}\|/\|\lambda^{(k)}\| < tol \text{ or } k > itmax
```

Velocità di convergenza: autovettori

Teorema

Supponiamo valgano le ipotesi del Teorema 1. Sia $x_i^{(k)} = X^{(k)}e_i$ e sia $y_i^{(k)} = U\begin{pmatrix} I_p \\ S^{(k)} \end{pmatrix}$ e_i (cfr. dimostrazione del Teorema 2). Allora:

$$\sin \angle (x_i^{(k)}, y_i^{(k)}) \le c \left(\frac{\lambda_{p+1}}{\lambda i}\right)^k, \qquad 1 \le i \le p$$

Usando la dimostrazione vista in precedenza:

Corollario

$$\sin \angle (x_i^{(k)}, u_i) \le c_3 \left(\frac{\lambda_{p+1}}{\lambda i}\right)^k$$

Velocità di convergenza: autovalori

• Algoritmo 2:

$$|\lambda_i^{(k)} - \lambda_i| = O\left(\left|\frac{\lambda_{p+1}}{\lambda_i}\right|^k\right)$$

• Algoritmi 3 e 4, se *A* è simmetrica definita positiva:

$$\lambda_j^{(k+1)^2} = \frac{\|Ax_j^{(k)}\|^2}{\|x_j^{(k)}\|^2} = x_j^{(k)^*} A^2 x_j^{(k)}$$

e vale:

$$|\lambda_j^{(k+1)} - \lambda_j| = O\left(\frac{\lambda_{p+1}}{\lambda_i}\right)^{2k}$$

Velocità di convergenza: autovalori

• Algoritmo 2:

$$|\lambda_i^{(k)} - \lambda_i| = O\left(\left|\frac{\lambda_{p+1}}{\lambda_i}\right|^k\right)$$

• Algoritmi 3 e 4, se *A* è simmetrica definita positiva:

$$\lambda_j^{(k+1)^2} = \frac{\|Ax_j^{(k)}\|^2}{\|x_j^{(k)}\|^2} = x_j^{(k)^*} A^2 x_j^{(k)}$$

e vale:

$$|\lambda_j^{(k+1)} - \lambda_j| = O\left(\frac{\lambda_{p+1}}{\lambda_j}\right)^{2k}$$

Sperimentazione numerica: confronto tra algoritmi

I quattro algoritmi sono stati confrontati, al variare di $n \in p$, in termini di:

- it: numero di iterazioni svolte per ciascuna istanza;
- time: tempo di risoluzione di un'istanza, in secondi;
- it_time: tempo di esecuzione di un'iterazione, in secondi;
- values_err: errore relativo massimo commesso sull'approssimazione degli autovalori (assumendo come esatti quelli calcolati da MATLAB)
- vectors_err: errore relativo in norma massimo commesso sull'approssimazione degli autovettori (assumendo come esatti quelli calcolati da MATLAB)

É stata eseguita una sperimentazione nel caso di A matrice sparsa per i seguenti valori di p e n:

- n = 1000, p = 5 Risultati
- n = 1000, p = 10 Risultati
- n = 1000, p = 15 Risultati
- n = 1000, p = 20 Risultati
- n = 5000, p = 5 Risultati
- n = 10000, p = 5 Risultati

É stata eseguita una sperimentazione nel caso di A matrice sparsa per i seguenti valori di p e n:

- n = 1000, p = 5 Risultati
- n = 1000, p = 10 Risultati
- n = 1000, p = 15 Risultati
- n = 1000, p = 20 Risultati
- n = 5000, p = 5 Risultati
- n = 10000, p = 5 Risultati

Sono stati ricavati interessanti risultati interessanti risultati:

• confronto con l'analisi teorica del costo e della convergenza

É stata eseguita una sperimentazione nel caso di A matrice sparsa per i seguenti valori di p e n:

- n = 1000, p = 5 Risultati
- n = 1000, p = 10 Risultati
- n = 1000, p = 15 Risultati
- n = 1000, p = 20 Risultati
- n = 5000, p = 5 Risultati
- n = 10000, p = 5 Risultati

Sono stati ricavati interessanti risultati interessanti risultati:

- confronto con l'analisi teorica del costo e della convergenza
- comportamento al crescere di p

É stata eseguita una sperimentazione nel caso di A matrice sparsa per i seguenti valori di p e n:

- n = 1000, p = 5 Risultati
- n = 1000, p = 10 Risultati
- n = 1000, p = 15 Risultati
- n = 1000, p = 20 Risultati
- n = 5000, p = 5 Risultati
- n = 10000, p = 5 Risultati

Sono stati ricavati interessanti risultati interessanti risultati:

- confronto con l'analisi teorica del costo e della convergenza
- comportamento al crescere di p
- differenze tra A simmetrica qualsiasi o definita positiva

É stata eseguita una sperimentazione nel caso di A matrice sparsa per i seguenti valori di p e n:

- n = 1000, p = 5 Risultati
- n = 1000, p = 10 Risultati
- n = 1000, p = 15 Risultati
- n = 1000, p = 20 Risultati
- n = 5000, p = 5 Risultati
- n = 10000, p = 5 Risultati

Sono stati ricavati interessanti risultati interessanti risultati:

- o confronto con l'analisi teorica del costo e della convergenza
- comportamento al crescere di p
- differenze tra A simmetrica qualsiasi o definita positiva
- comportamento al crescere di n



Tabella: n = 1000, p = 5, itmax = 5000, $tol = 10^{-10}$

Algoritmo	it	time	$\mathtt{it}_{\mathtt{-}}\mathtt{time}$	values_err	vectors_err
1	3846	0.996	2.580×10^{-4}	1.857×10^{-6}	0.030
2	3287	1.805	5.482×10^{-4}	$5.545 imes 10^{-4}$	5.251×10^{-4}
3	2765	0.795	2.853×10^{-4}	8.536×10^{-4}	7.385×10^{-4}
4	2765	0.942	3.402×10^{-4}	8.536×10^{-4}	7.385×10^{-4}
Tabella: n =	= 1000,	A def.	positiva, $p=5$,	$\mathtt{itmax} = 5000,$	$tol = 10^{-10}$
Algoritmo	it	time	$\mathtt{it}_{\mathtt{-}}\mathtt{time}$	values_err	vectors_err
1	3468	0.915	2.652×10^{-4}	1.242×10^{-6}	0.030
2	1832	1.031	5.653×10^{-4}	1.393×10^{-7}	3.363×10^{-4}
3	1832	0.524	2.872×10^{-4}	1.391×10^{-7}	3.362×10^{-4}
4	1832	0.623	3.437×10^{-4}	1.391×10^{-7}	3.362×10^{-4}

Tabella: n = 1000, p = 10, itmax = 7500, $tol = 10^{-10}$

Algoritmo	it	time	$\mathtt{it_time}$	values_err	vectors_err
1	4647	2.363	5.095×10^{-4}	1.124×10^{-5}	0.073
				1.552×10^{-4}	
				2.248×10^{-4}	
4	2737	1.697	6.199×10^{-4}	2.249×10^{-4}	8.769×10^{-4}

Tabella: n = 1000, A def. positiva, p = 10, itmax = 7500, $tol = 10^{-10}$

Algoritmo	it	time	it_time	values_err	vectors_err
			5.087×10^{-4}		
2	2377	2.325	9.755×10^{-4}	4.866×10^{-8}	1.833×10^{-4}
3	1		$4.887 imes 10^{-4}$		
4	2376	1.501	$6.314 imes 10^{-4}$	$4.873 imes 10^{-8}$	$1.847 imes 10^{-4}$

Tabella: n = 1000, p = 15, itmax = 7500, $tol = 10^{-10}$

Algoritmo	it	time	it_time	values_err	vectors_err
1	7087	5.881	8.294×10^{-4}	$1.076 imes 10^{-5}$	0.146
2	4571	7.071	1.532×10^{-3}	1.554×10^{-4}	1.994×10^{-4}
3	3687	2.712	7.328×10^{-4}	1.412×10^{-4}	3.282×10^{-4}
4	3687	3.747	1.047×10^{-3}	1.411×10^{-4}	3.282×10^{-4}
Tabella: n =	1000,	A def. p	positiva, $p=15$	$\mathtt{itmax} = 7500$	$, tol = 10^{-10}$

Algoritmo	it	time	$\mathtt{it_time}$	values_err	vectors_er
1	6970	5.891	8.465×10^{-4}	0.019	0.173
2	4420	6.961	1.644×10^{-3}	4.328×10^{-7}	0.006
3	4399	2.302	7.537×10^{-4}	4.405×10^{-7}	0.006
4	4385	4.494	1.079×10^{-3}	4.411×10^{-7}	0.006
		<u> </u>	<u> </u>		$ \begin{array}{c ccccccccccccccccccccccccccccccccccc$



Tabella: n = 1000, p = 20, itmax = 7500, $tol = 10^{-10}$

Algoritmo	it	time	$\mathtt{it}_{\mathtt{-}}\mathtt{time}$	values_err	vectors_err
1	7293	8.377	1.198×10^{-3}	8.529×10^{-6}	0.104
				4.003×10^{-6}	
3	2735	2.409	8.809×10^{-4}	8.510×10^{-5}	1.473×10^{-4}
4	2735	3.8673	1.447×10^{-3}	8.514×10^{-5}	1.473×10^{-4}

Tabella: n=1000, A def. positiva, p=20, itmax=7500, $tol=10^{-10}$

Algoritmo	it	time	$\mathtt{it}_{\mathtt{-}}\mathtt{time}$	$values_err$	vectors_err
			1.267×10^{-3}		0.163
2			2.299×10^{-3}		
3	I		9.062×10^{-4}		
4	4835	6.951	1.435×10^{-3}	9.525×10^{-7}	0.009



Tabella: n = 5000, p = 5, itmax = 5000, $tol = 10^{-10}$

Algoritmo	it	time	$\mathtt{it}_{\mathtt{-}}\mathtt{time}$	values_err	vectors_err
1	3336	6.388	1.945×10^{-3}	9.361×10^{-7}	0.033
2	2163	8.214	3.939×10^{-3}	$\begin{array}{c} 9.361 \times 10^{-7} \\ 1.266 \times 10^{-4} \end{array}$	0.003
3	1883	3.578	1.971×10^{-3}	1.833×10^{-3}	0.004
4	1883	3.963	2.184×10^{-3}	1.833×10^{-3}	0.004

Tabella: n = 5000, A def. positiva, p = 5, itmax = 5000, $tol = 10^{-10}$

Algoritmo	it	time	$\mathtt{it}_{\mathtt{-}}\mathtt{time}$	$values_err$	vectors_err
			1.947×10^{-3}		
			3.866×10^{-3}		
			1.915×10^{-3}		
4	1730	3.556	2.101×10^{-3}	4.735×10^{-7}	0.003



Tabella: n = 10000, p = 5, itmax = 5000, $tol = 10^{-10}$

Algoritmo	it	time	$\mathtt{it}_{\mathtt{_}}\mathtt{time}$	values_err	vectors_err
1	4515	10.116	2.229×10^{-3}	1.851×10^{-6}	0.050
2	2167	10.088	4.715×10^{-3}	1.006×10^{-4}	5.528×10^{-4}
3	1527	3.427	2.206×10^{-3}	1.875×10^{-3}	0.003
4	1527	3.925	2.613×10^{-3}	1.859×10^{-3}	0.003
Tabella: n =	10000,	A def. p	ositiva, $p=5$,	$\mathtt{itmax} = 5000,$	$tol = 10^{-10}$
Algoritmo	it	time	$\mathtt{it}_{\mathtt{-}}\mathtt{time}$	values_err	vectors_err
1	4417	9.870	2.235×10^{-3}	6.695×10^{-5}	0.374
2	2896	13.422	4.607×10^{-3}	3.575×10^{-8}	0.020
3	2897	6.402	2.221×10^{-3}	3.574×10^{-8}	0.020
4	2897	7.168	2.549×10^{-3}	3.574×10^{-8}	0.020

Sperimentazione numerica: confronto con la velocità di convergenza prevista

Possiamo inoltre analizzare graficamente la velocità di convergenza di autovalori e autovettori e in particolare chiederci se:

- la convergenza è effettivamente lineare
- il fattore di convergenza è quello ricavato teoricamente

Algoritmo 1

Figura: Algoritmo 1. Plot in scala semilogaritmica dell'errore.

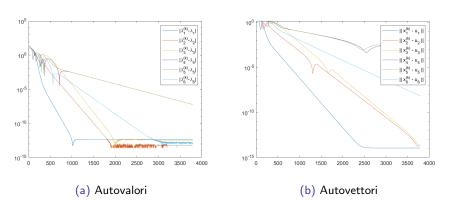


Figura: Algoritmo 1. Confronto, in scala semilogaritmica, tra la velocità di convergenza prevista teoricamente e quella sperimentale per gli autovettori.

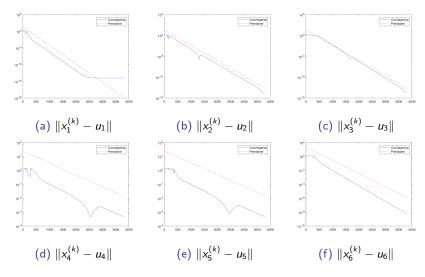
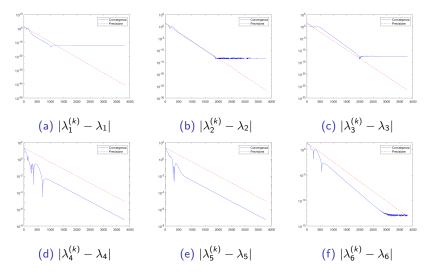


Figura: Algoritmo 1. Confronto, in scala semilogaritmica, tra la velocità di convergenza prevista teoricamente e quella sperimentale per gli autovalori.



Algoritmo 2

Figura: Algoritmo 2. Plot in scala semilogaritmica dell'errore.

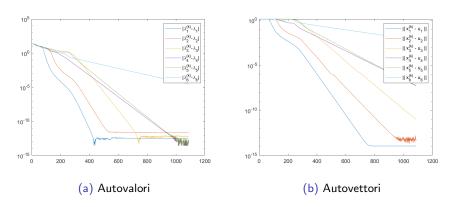


Figura: Algoritmo 2. Confronto, in scala semilogaritmica, tra la velocità di convergenza prevista teoricamente e quella sperimentale per gli autovettori.

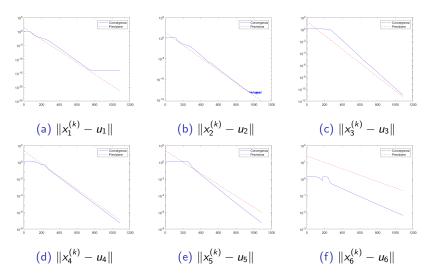
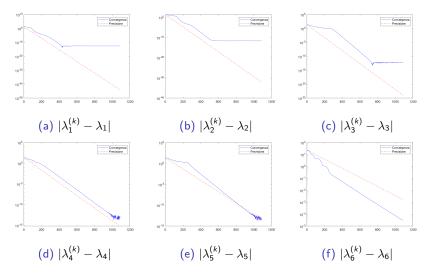


Figura: Algoritmo 2. Confronto, in scala semilogaritmica, tra la velocità di convergenza prevista teoricamente e quella sperimentale per gli autovalori.



Algoritmo 3

Figura: Algoritmo 3. Plot in scala semilogaritmica dell'errore.

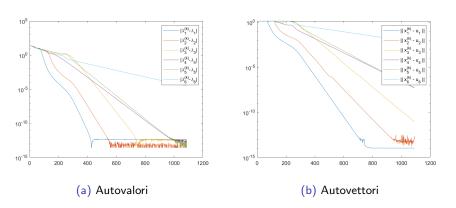


Figura: Algoritmo 3. Confronto, in scala semilogaritmica, tra la velocità di convergenza prevista teoricamente e quella sperimentale per autovettori.

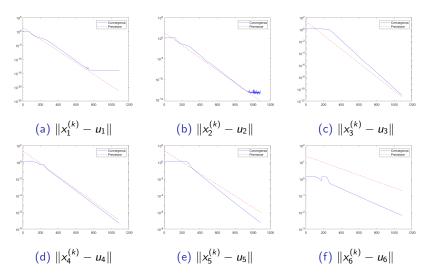
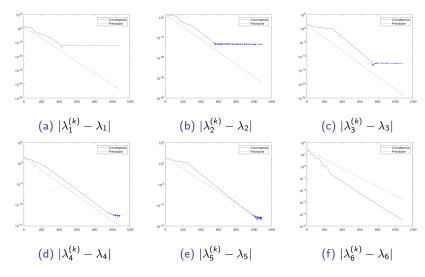


Figura: Algoritmo 3. Confronto, in scala semilogaritmica, tra la velocità di convergenza prevista teoricamente e quella sperimentale per autovalori.



Algoritmo 4

Figura: Algoritmo 4. Plot in scala semilogaritmica dell'errore.

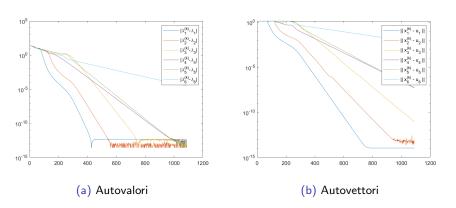


Figura: Algoritmo 4. Confronto, in scala semilogaritmica, tra la velocità di convergenza prevista teoricamente e quella sperimentale per gli autovettori.

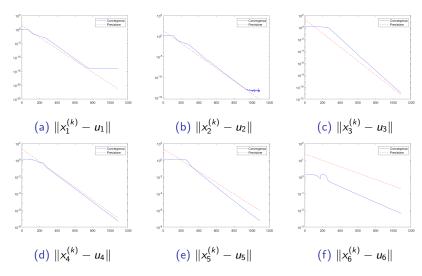
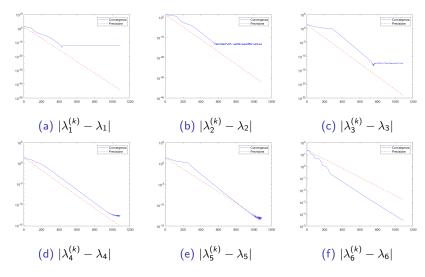


Figura: Algoritmo 4. Confronto, in scala semilogaritmica, tra la velocità di convergenza prevista teoricamente e quella sperimentale per gli autovalori.



Riferimenti bibliografici

- [1] Peter Arbenz. Numerical Methods for Solving Large Scale Eigenvalue Problems. 2016.
- [2] Dario Bini. Problemi di vibrazioni. 2020.
- [3] Dario Bini, Milvio Capovani e Ornella Menchi. *Metodi numerici per l'algebra lineare*. Zanichelli, 1988.
- [4] Beresford N. Parlett. «14. Subspace Iteration». In: The Symmetric Eigenvalue Problem. Society for Industrial e Applied Mathematics, pp. 323–337.
- [5] H. Rutishauser. «Simultaneous Iteration Method for Symmetric Matrices». In: Handbook for Automatic Computation: Volume II: Linear Algebra. Springer Berlin Heidelberg, 1971, pp. 284–302.